Laporan Praktikum 2 — Praproses Data

Nama: Firdaus Mangkona **NRP:** 5054251003

Dataset: House Prices – Advanced Regression Techniques (Kaggle) **File data:** `train.csv` (1.460 baris × 81 kolom) **Alat:** Python 3, pandas, NumPy, Matplotlib, Seaborn, scikit-learn

---

1. Pendahuluan

Praktikum ini bertujuan mempersiapkan dataset *House Prices* agar siap digunakan untuk analisis maupun pemodelan *machine learning*. Kualitas data sangat menentukan performa model, sehingga tahapan praproses meliputi: **pembersihan data** (nilai hilang dan data tidak konsisten), **deteksi & penanganan outlier**, **transformasi data** (standardisasi dan *one-hot encoding*), serta **reduksi dimensi** (analisis korelasi dan PCA).

Dataset berisi informasi penjualan rumah di Ames, Iowa, Amerika Serikat. Setiap baris mewakili satu rumah dengan 80 atribut (ukuran, tahun dibangun, kualitas, kondisi, dsb.) dan satu target `SalePrice` (harga jual).

---

2. Import dan Eksplorasi Awal

Dataset diimpor dengan `pandas.read_csv()`. Hasil pemeriksaan struktur data:

Properti	Nilai
Jumlah baris	1.460
Jumlah kolom	81
Kolom numerik	38
Kolom kategorikal (object)	43
Target	`SalePrice`

Statistik ringkas kolom `SalePrice` (target):

Statistik	Nilai (USD)
Rata-rata	180.921
Median	163.000
Minimum	34.900
Maksimum	755.000
Std. deviasi	79.442

Kolom `Id` hanyalah penanda baris sehingga akan dibuang pada tahap transformasi.

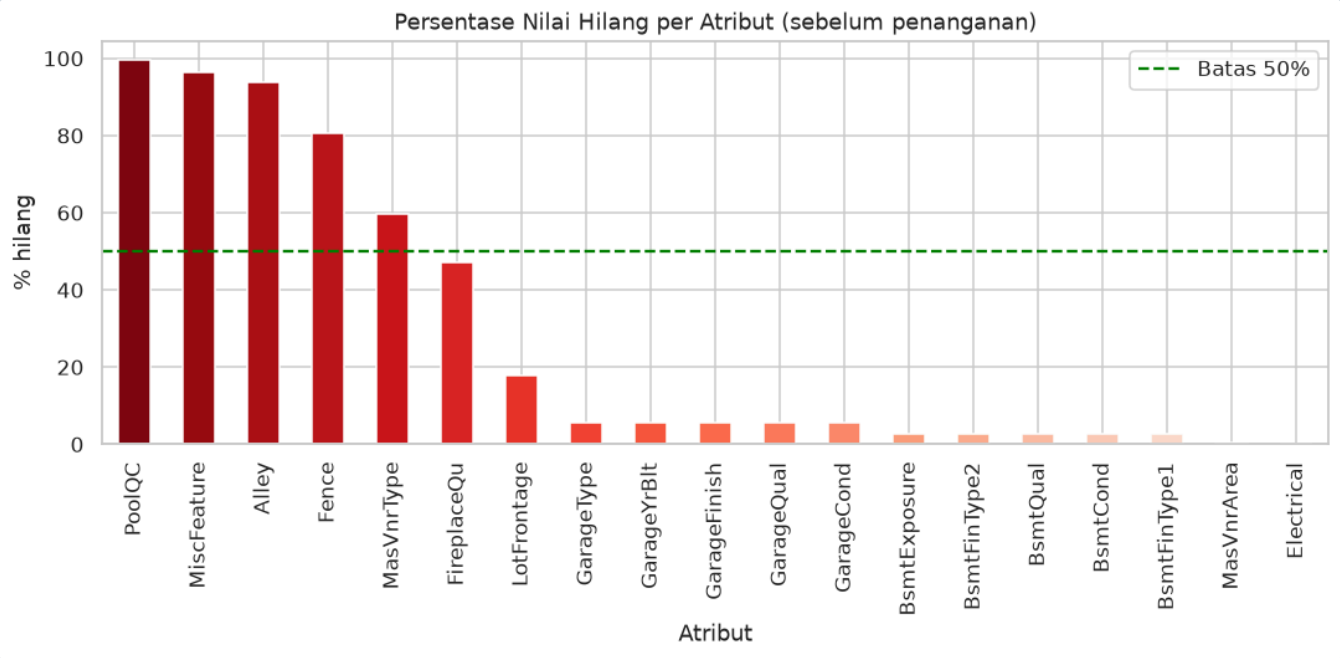
---

3. Pembersihan Data

3.1 Pemeriksaan Nilai Hilang

Secara keseluruhan terdapat **7.829 nilai hilang** yang tersebar di 19 atribut. Sepuluh atribut dengan nilai hilang terbanyak:

Atribut	Jumlah Hilang	% Hilang
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
MasVnrType	872	59,73%
FireplaceQu	690	47,26%
LotFrontage	259	17,74%
GarageType	81	5,55%
GarageYrBlt	81	5,55%
GarageFinish	81	5,55%



> **Catatan penting:** pada dataset ini, banyak nilai `NA` sebenarnya bermakna *"tidak memiliki fitur tersebut"* — misalnya `PoolQC = NA` berarti "tidak ada kolam", `Alley = NA` berarti "tidak ada akses gang", `FireplaceQu = NA` berarti "tidak ada perapian", dan `Bsmt*` / `Garage* = NA` berarti "tidak ada basement/garasi".

3.2 Penghapusan Atribut dengan Nilai Hilang > 50%

Sesuai ketentuan, atribut dengan proporsi nilai hilang lebih dari 50% dihapus:

Atribut dihapus	% Hilang	Keterangan
PoolQC	99,52%	nyaris semua rumah tanpa kolam
MiscFeature	96,30%	nyaris semua tanpa fitur tambahan
Alley	93,77%	nyaris semua tanpa gang
Fence	80,75%	mayoritas tanpa pagar
MasVnrType	59,73%	mayoritas tanpa veneer batu

3.3 Penanganan Nilai Hilang Tersisa

Atribut yang tersisa ditangani berdasarkan makna domainnya:

- **Kategorikal bermakna "tidak ada"** → diisi `"None"`: `FireplaceQu`, `BsmtQual`, `BsmtCond`, `BsmtExposure`, `BsmtFinType1`, `BsmtFinType2`, `GarageType`, `GarageFinish`, `GarageQual`, `GarageCond`.
- **`Electrical`** (1 nilai hilang) → diisi **modus** (`SBrkr`).
- **`LotFrontage`** (259 hilang, distribusi miring) → diisi **median**.
- **`MasVnrArea`** (8 hilang) → diisi **0** (tanpa veneer batu).
- **`GarageYrBlt`** (81 hilang) → diisi **tahun rumah dibangun** (`YearBuilt`), sebagai nilai netral untuk rumah tanpa garasi.

Hasil: **jumlah nilai hilang menjadi 0**.

3.4 Pemeriksaan Konsistensi Data

Pemeriksaan	Hasil
Baris duplikat (`Id`)	0
Nilai negatif pada kolom numerik	0
`YearBuilt > YrSold` (tahun dibangun > tahun jual)	0
`GarageCars = 0` tetapi `GarageArea > 0`	0
`GarageArea = 0` tetapi `GarageType` terisi	0

Tidak ditemukan data yang tidak konsisten.

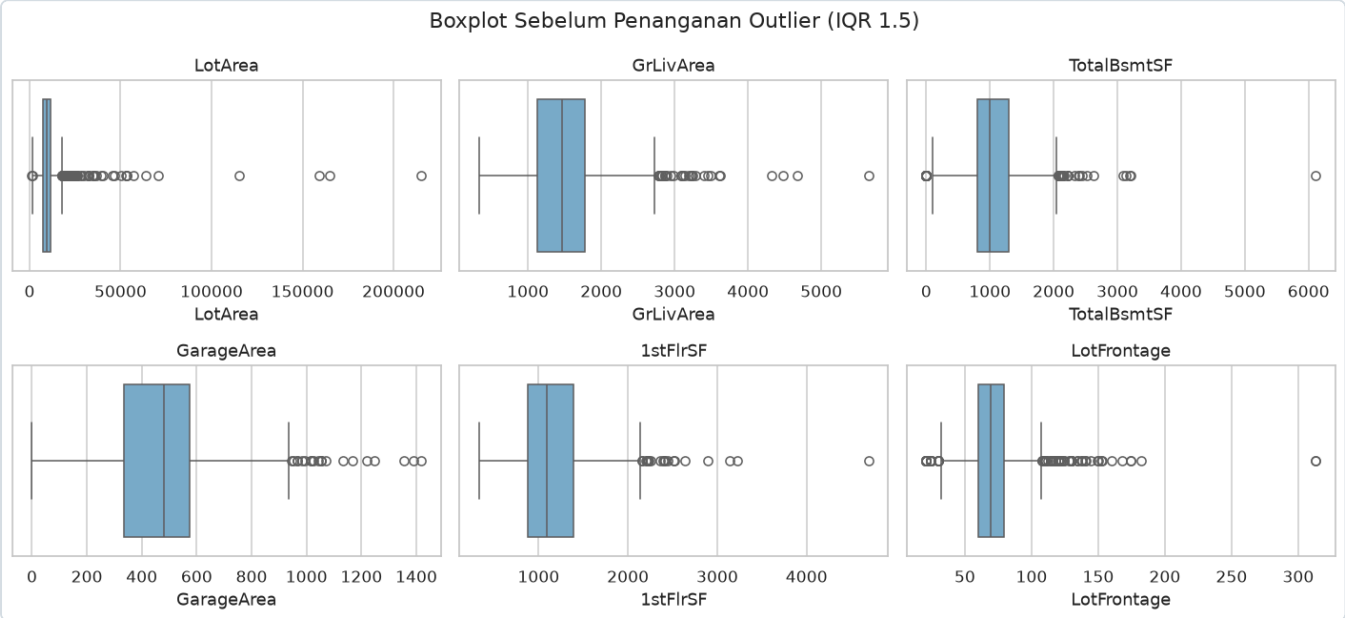
---

4. Deteksi dan Penanganan Outlier

4.1 Deteksi

Outlier dideteksi pada 19 fitur kontinu (luas/area) menggunakan **boxplot** dan metode **IQR (Interquartile Range)** dengan batas Q1 − 1,5·IQR dan Q3 + 1,5·IQR. Total terdapat **1.153 flag outlier**.

Fitur	Outlier	Fitur	Outlier
EnclosedPorch	208	GarageArea	21
BsmtFinSF2	167	1stFlrSF	20
ScreenPorch	116	BsmtFinSF1	7
LotFrontage	106	PoolArea	7
MasVnrArea	98	2ndFlrSF	2
OpenPorchSF	77	BsmtUnfSF	29
LotArea	69	LowQualFinSF	26
TotalBsmtSF	61	3SsnPorch	24
MiscVal	52	WoodDeckSF	32
GrLivArea	31		



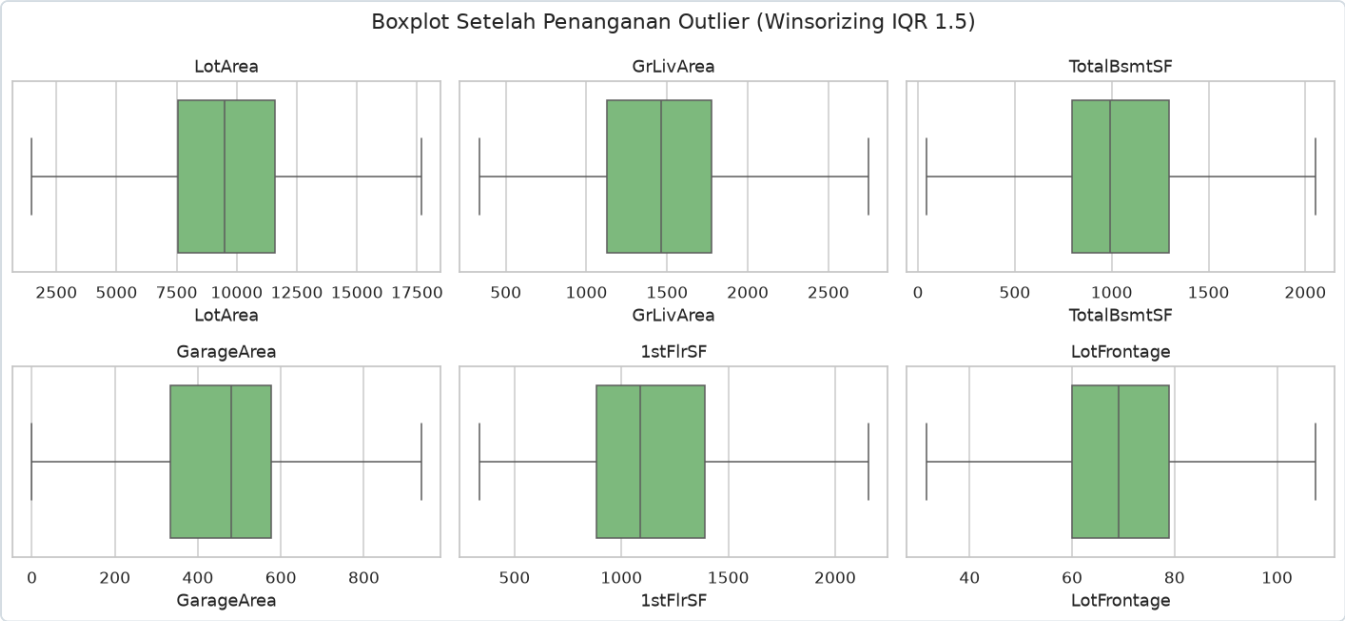
4.2 Penanganan: Winsorizing

Keputusan: outlier disesuaikan (di-*cap*), bukan dihapus. Alasannya:

1. Dataset hanya 1.460 baris — menghapus outlier akan membuang data sah dan berharga.
2. Outlier berupa rumah-rumah berukuran sangat besar/istimewa yang tetap merupakan observasi valid, bukan kesalahan input.

3. *Winsorizing* (menahan nilai pada batas IQR) membuat distribusi lebih normal tanpa kehilangan observasi.

Setiap fitur kontinu di-*clip* ke rentang [Q1 − 1,5·IQR, Q3 + 1,5·IQR]. Hasilnya **0 outlier** tersisa.



---

5. Transformasi Data

5.1 Standardisasi (Z-score)

Seluruh kolom numerik distandardisasi dengan `StandardScaler` sehingga memiliki rata-rata 0 dan standar deviasi 1. Standardisasi dipilih (bukan normalisasi Min-Max) karena sesuai untuk PCA dan distribusi data setelah winsorizing sudah relatif simetris. Kolom ordinal/integer (mis. `OverallQual`, `YearBuilt`, jumlah kamar) tetap diperlakukan numerik karena memiliki urutan yang alami.

5.2 One-Hot Encoding

Kolom kategorikal (38 kolom object) diubah menjadi kolom *dummy* biner menggunakan `pd.get_dummies(..., drop_first=True)`. `drop_first=True` digunakan untuk menghindari multikolinearitas (*dummy variable trap*).

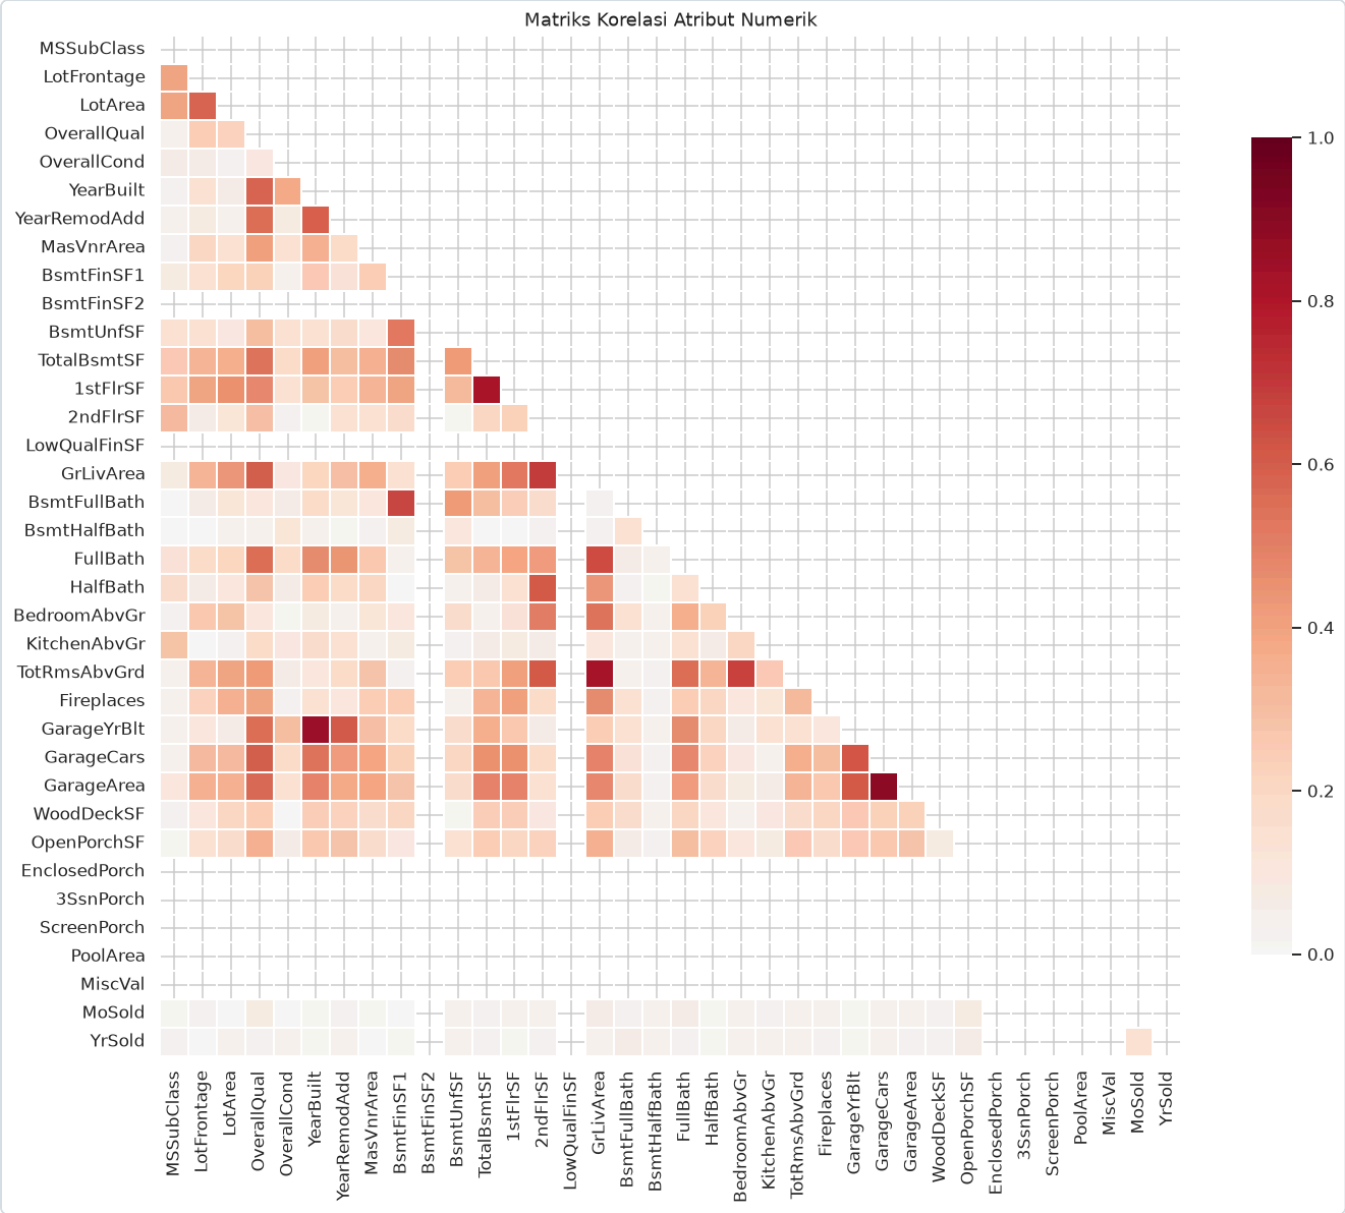
Setelah transformasi, jumlah fitur berkembang dari 80 menjadi **240 fitur**.

---

6. Reduksi Dimensi

6.1 Analisis Korelasi

Matriks korelasi dihitung pada atribut numerik untuk menemukan pasangan yang sangat berkorelasi (redundan).



Pasangan dengan korelasi > 0,8 yang ditemukan:

Pasangan	Korelasi	Atribut yang dibuang	Alasan
GarageArea ↔ GarageCars	0,893	`GarageCars`	jumlah mobil kurang granular daripada luas
GarageYrBlt ↔ YearBuilt	0,845	`GarageYrBlt`	informasi tahun tumpang tindih
TotRmsAbvGrd ↔ GrLivArea	0,836	`TotRmsAbvGrd`	jumlah kamar redundan dengan luas
1stFlrSF ↔ TotalBsmtSF	0,807	*(dipertahankan)*	mengukur bagian rumah berbeda

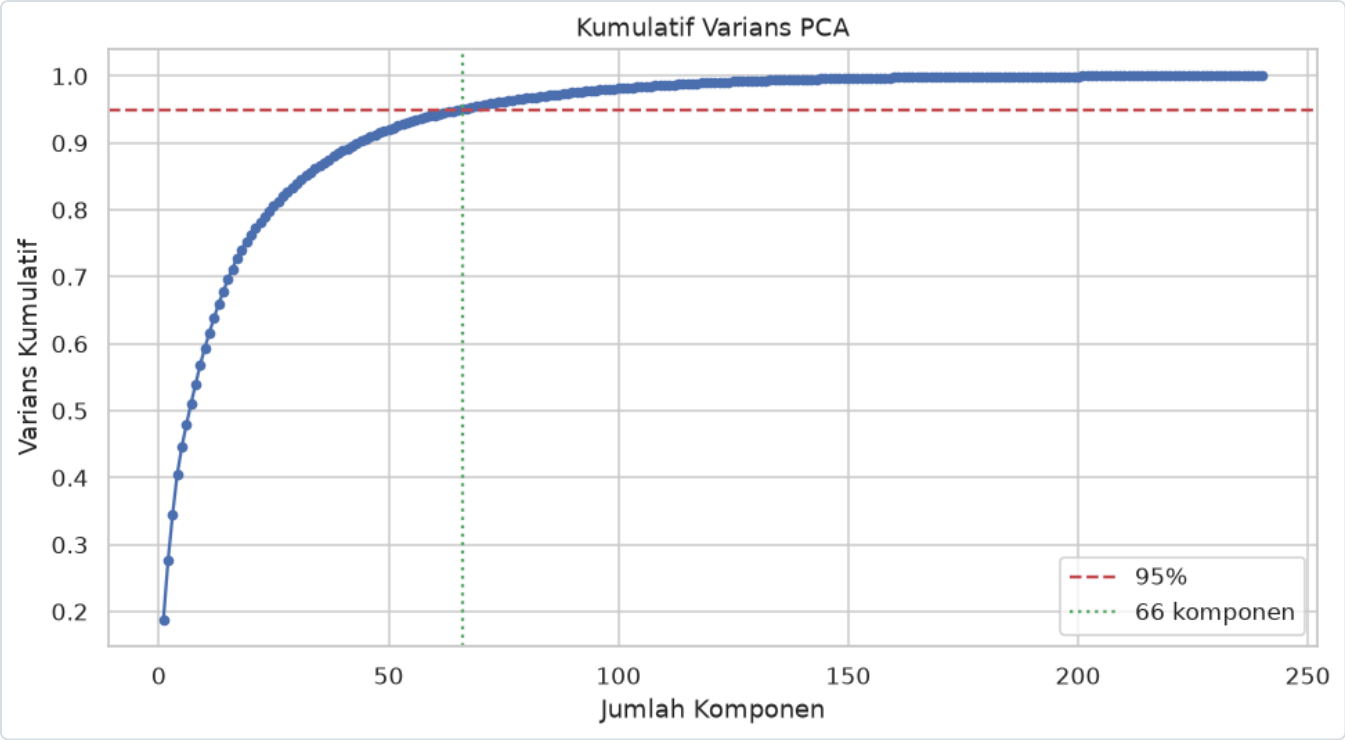
Tiga atribut dibuang (`GarageCars`, `GarageYrBlt`, `TotRmsAbvGrd`). Pasangan `1stFlrSF` – `TotalBsmtSF` dipertahankan karena lantai 1 dan basement adalah bagian rumah yang berbeda secara konseptual.

6.2 Principal Component Analysis (PCA)

PCA diterapkan pada 240 fitur hasil transformasi untuk mereduksi dimensi. Hasilnya:

- **44 komponen** cukup untuk mempertahankan **90%** varians.

- **66 komponen** cukup untuk mempertahankan **95%** varians.



Dengan 66 komponen utama, dimensi data berkurang dari 240 menjadi **66** (~72% reduksi) sambil tetap mempertahankan 95% informasi.

---

7. Ringkasan Dataset Akhir

Tahap	Sebelum	Sesudah
Nilai hilang	7.829 nilai	**0**
Kolom dibuang (>50% hilang)	—	5 kolom
Data tidak konsisten	—	0
Outlier (IQR 1,5)	1.153 flag	**0** (winsorizing)
Fitur setelah encoding + scaling	80	240 fitur
Fitur setelah reduksi korelasi	—	−3 fitur
Fitur setelah PCA (95% varian)	240	**66 komponen**

Dataset akhir yang dikumpulkan (`5054251003_Firdaus_Mangkona_Tugas_Praproses_Data.csv`) berisi 1.460 baris × 241 kolom, terdiri dari 240 fitur hasil *standardisasi* + *one-hot encoding* dan kolom target `SalePrice`. Versi hasil reduksi PCA (1.460 × 67) disimpan terpisah sebagai dokumentasi.

---

8. Kesimpulan

Seluruh tahapan praproses telah dilakukan terhadap dataset *House Prices*:

1. **Pembersihan data** — 5 kolom dengan >50% nilai hilang dihapus, nilai hilang tersisa diimputasi sesuai makna domain (0 nilai hilang tersisa), dan tidak ditemukan data tidak konsisten.
2. **Outlier** — 1.153 outlier pada fitur kontinu ditangani dengan *winsorizing* (IQR 1,5) sehingga distribusi lebih normal tanpa kehilangan data.
3. **Transformasi** — kolom numerik distandardisasi (z-score) dan 38 kolom kategorikal di-*one-hot encode*, menghasilkan 240 fitur.
4. **Reduksi dimensi** — 3 fitur redundan dibuang berdasarkan korelasi, lalu PCA meringkas 240 fitur menjadi 66 komponen utama (95% varians).

Dataset akhir kini bersih, konsisten, terstandardisasi, dan siap digunakan untuk pemodelan *machine learning*.