# Laporan Analisis: Scraping & Exploratory Data Analysis (EDA)

**Dataset Item Wynncraft**

*Nama: Firdaus Mangkona | NIM: 5054251003 | Tugas 1 — Scraping & EDA*

## 1. Deskripsi Dataset

Dataset yang dianalisis merupakan hasil scraping dari Wynncraft Item Database API v3 (https://api.wynncraft.com/v3/item/database?full_result). Data ditarik menggunakan library requests, kemudian disimpan dalam dua format: JSON mentah (wynncraft_items_database.json) dan CSV tabular (wynncraft_items.csv) hasil pandas.json_normalize.

Karakteristik umum dataset:

| Aspek | Keterangan |
|---|---|
| **Jumlah baris (item)** | 6.725 item |
| **Jumlah kolom (atribut)** | 630 kolom |
| **Sumber** | REST API Wynncraft v3 (full_result) |
| **Format** | JSON → CSV (flattened) |
| **Tipe kolom** | 436 float64, 191 string, 2 object, 1 int64 |

Struktur API bersifat sangat bersarang (nested), sehingga setelah normalisasi jumlah kolom membengkak menjadi 630. Atribut penting yang digunakan dalam analisis ini antara lain:

- Identitas item: displayName, internalName, type, subType
- Kategorikal: tier (kelangkaan), restriction, dropRestriction, emblem
- Numerik: requirements.level, base.baseHealth, serta requirements.strength, dexterity, intelligence, defence, agility
- Lainnya: elements, lore, identifications.*, majorIds.*

Berdasarkan tipenya, atribut diklasifikasikan sebagai berikut:

- Nominal: type, subType, dropRestriction (tanpa urutan hierarki).
- Ordinal: tier — Normal < Unique < Rare < Legendary < Fabled < Mythic.
- Numerik diskrit: requirements.level, requirements.strength, dst.
- Numerik kontinu (skala besar): base.baseHealth dan atribut damage.

## 2. Statistik Deskriptif

### a. Atribut numerik

| Atribut | Count | Mean | Std | Min | Q1 | Median | Q3 | Max |
|---|---|---|---|---|---|---|---|---|
| **requirements.level** | 6.725 | 69,55 | 33,28 | 1 | 42 | 75 | 98 | 120 |
| **base.baseHealth** | 2.471 | 1.532,17 | 1.562,48 | −3.500 | 200 | 1.000 | 2.800 | 7.500 |
| **requirements.strength** | 1.473 | 36,13 | 18,77 | 2 | 20 | 35 | 50 | 110 |
| **requirements.dexterity** | 1.385 | 36,78 | 19,22 | 2 | 20 | 35 | 50 | 120 |
| **requirements.intelligence** | 1.377 | 36,56 | — | 2 | — | — | — | 130 |
| **requirements.defence** | 1.425 | 36,89 | — | 2 | — | — | — | 115 |
| **requirements.agility** | 1.434 | 36,71 | — | 2 | — | — | — | 125 |

Catatan penting: atribut stat requirement (strength, dexterity, dst.) hanya terisi pada ±20% item (1.377–1.473 dari 6.725). Ini bukan data rusak, melainkan karena hanya item bertipe armour/weapon tertentu yang memiliki attribute requirements; sisanya bernilai kosong.

### b. Atribut kategorikal

**Distribusi tier (kelangkaan):**

| Tier | Jumlah |
|---|---|
| **unique** | 2.071 |
| **rare** | 1.640 |
| **legendary** | 948 |
| **normal** | 481 |
| **fabled** | 374 |
| **TIER_0 / TIER_1 / TIER_2 / TIER_3** | 233 / 250 / 294 / 195 |
| **mythic** | 127 |

**Distribusi type (jenis item):**

| Type | Jumlah |
|---|---|
| **weapon** | 2.390 |
| **armour** | 2.099 |
| **ingredient** | 972 |
| **accessory** | 924 |
| **tome** | 172 |
| **material** | 112 |
| **tool** | 52 |
| **charm** | 4 |

Catatan: label TIER_0–TIER_3 (total 972 item) berasal dari item bertipe ingredient yang memakai penamaan tingkat bahan, sehingga tidak sepenuhnya sebanding dengan tier equipment dan perlu diwaspadai saat agregasi.

## 3. Penanganan Data

### a. Nilai hilang (missing values)

- Dataset memiliki missing value masif dan terstruktur: hanya 6 dari 630 kolom yang terisi penuh (0% missing), sedangkan 548 kolom memiliki >90% missing.
- Missing value tertinggi didominasi kolom majorIds.* dan identifications.* yang mencapai 99,99% missing. Hal ini wajar karena mayoritas item tidak memiliki major ID atau identifikasi khusus.
- Keputusan: kolom dengan missing ekstrem tidak dihapus melainkan diabaikan dalam analisis kolom numerik utama. Untuk base.baseHealth, perhitungan statistik hanya memakai item bertipe armour (2.471 item), karena senjata tidak memiliki atribut ini.
- Fungsi pandas.json_normalize sengaja membiarkan NaN alih-alih mengisinya, agar struktur asli API tetap terjaga.

### b. Outlier

- Deteksi outlier memakai metode IQR (1,5 × IQR) pada requirements.level: Q1 = 42, Q3 = 98 → IQR = 56; batas bawah = −42, batas atas = 182.
- Hasil: 0 outlier. Seluruh nilai level berada di rentang wajar 1–120 sesuai level cap game, sehingga distribusi dianggap valid.
- Namun ditemukan 178 item dengan baseHealth negatif (nilai terendah −3.500). Nilai ini bukan kesalahan input, melainkan mekanisme desain game (item dengan health penalty sebagai trade-off terhadap bonus besar). Karena itu, outlier ini dipertahankan dan hanya diberi catatan saat interpretasi, bukan dihapus.

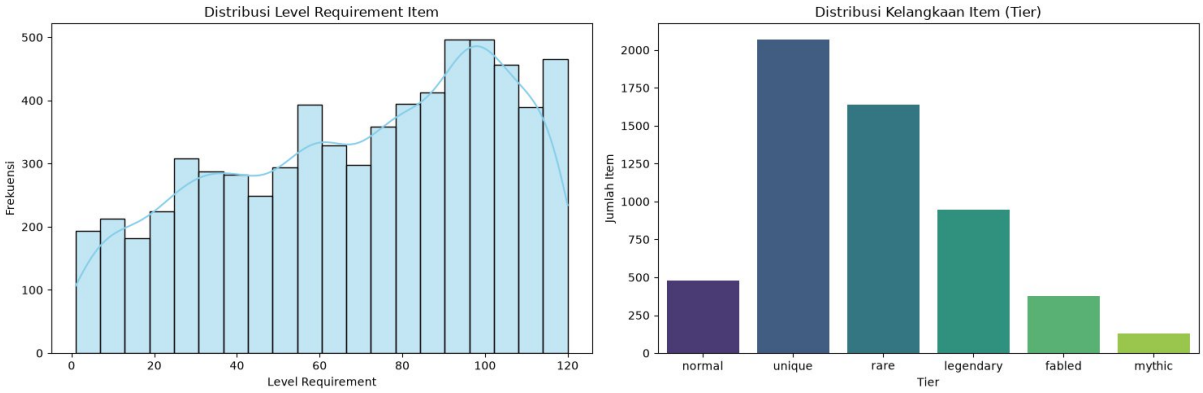
### c. Duplikasi & konsistensi tipe

- Terdapat 39 displayName duplikat; ini merujuk pada varian item (mis. hasil craft/rework) sehingga tidak dihapus.
- pd.read_csv memunculkan DtypeWarning pada ratusan kolom majorIds.*/icon.* karena tipe campuran. Untuk analisis ini dibiarkan; rekomendasi jangka panjang adalah dtype=str atau low_memory=False.

Ringkasan langkah penanganan: (1) mempertahankan struktur NaN asli, (2) memfilter item armour khusus untuk analisis baseHealth, (3) mengabaikan kolom yang missing ekstrem, (4) mempertahankan outlier negatif karena bermakna domain, dan (5) mencatat duplikasi nama sebagai varian yang sah.

# 4. Visualisasi & Interpretasi

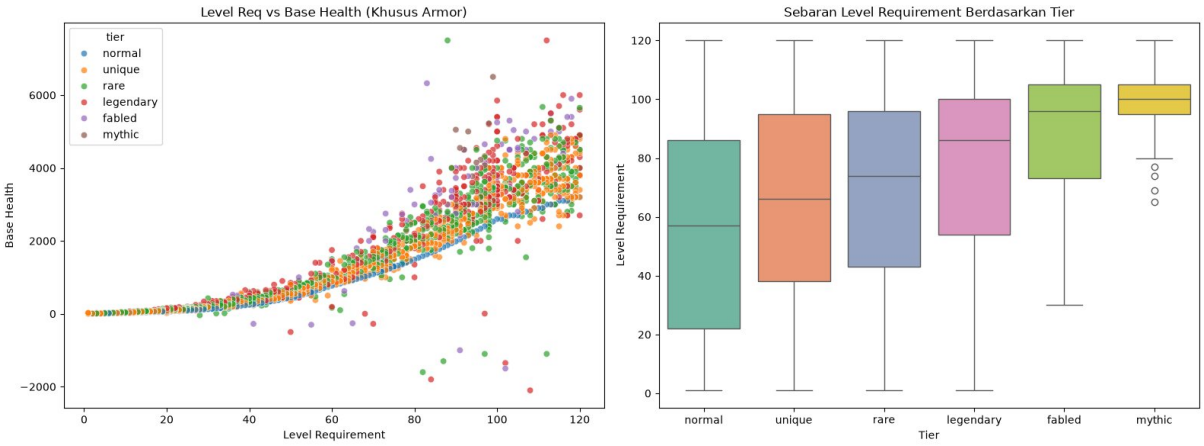
## a. Analisis Univariat




*Gambar 1. Distribusi level requirement dan distribusi tier item.*

- Histogram requirements.level: distribusi left-skewed — frekuensi item cenderung meningkat seiring bertambahnya level, memuncak di sekitar level 90–100, lalu sedikit menurun. Artinya konten item lebih banyak ditujukan untuk pemain level menengah–tinggi (end-game). Hanya 685 item (±10%) untuk level 1–20.
- Bar chart tier: pasar item didominasi Unique (2.071) dan Rare (1.640), sedangkan Mythic hanya 127 item (±1,9%). Pola piramida ini konsisten dengan desain MMORPG di mana item terkuat sengaja dibuat sangat langka.

## b. Analisis Bivariat

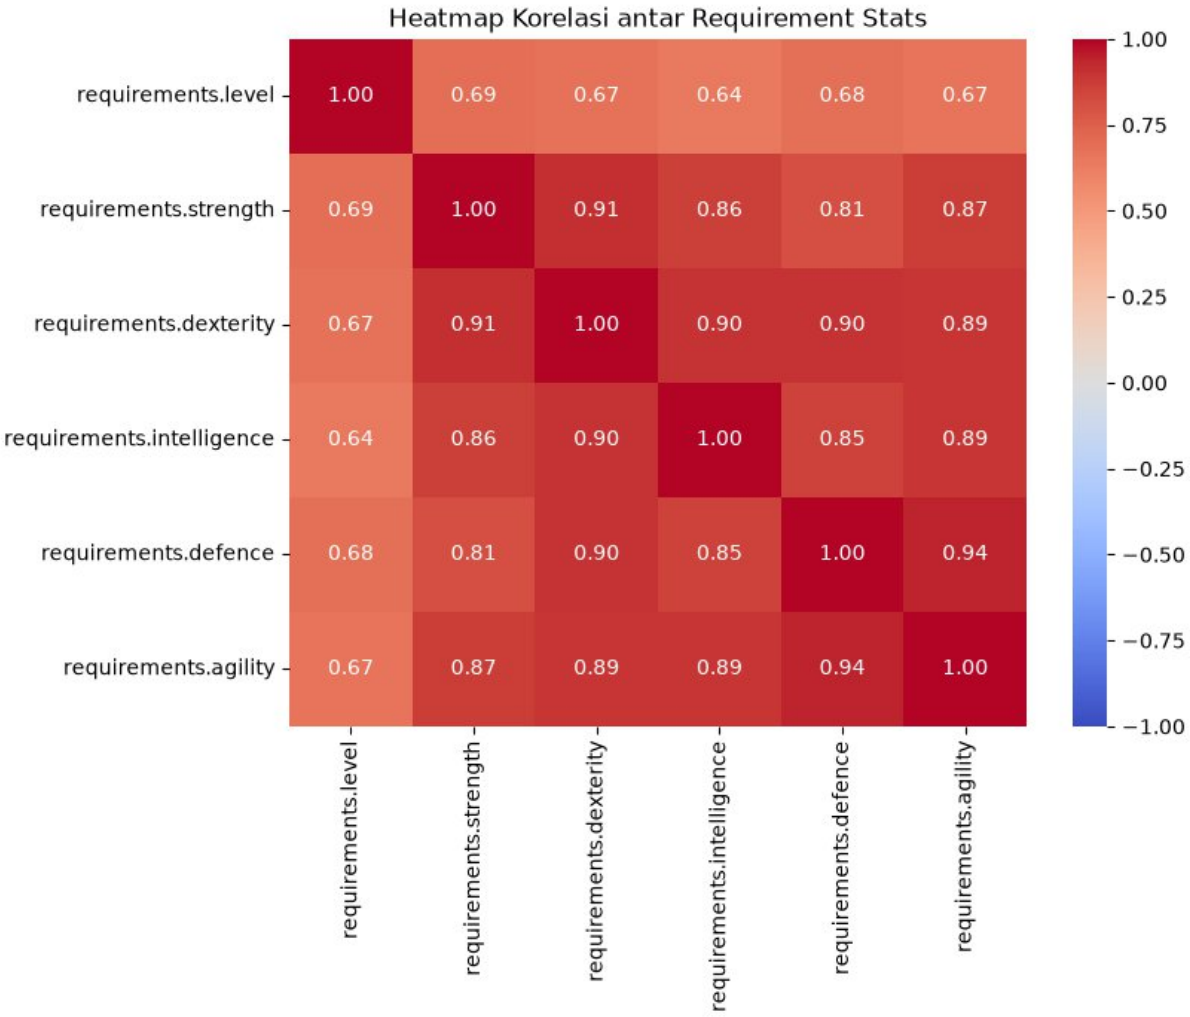



*Gambar 2. Scatter level vs base health dan boxplot level per tier.*

- Scatter plot (Level vs Base Health, khusus armour): terdapat hubungan positif non-linear — semakin tinggi level requirement, base health meningkat secara semakin curam (melengkung ke atas). Tier Legendary/Fabled/Mythic cenderung berada di kanan-atas grafik (level & HP tinggi), sementara tier Normal/Unique terkonsentrasi di kiri-bawah. Titik dengan health negatif menyebar di area bonus tinggi.

- Boxplot (Level per Tier): median level requirement naik konsisten mengikuti urutan tier: normal (57) < unique (66) < rare (74) < legendary (86) < fabled (96) < mythic (100). Tier Mythic punya sebaran paling sempit dan terkonsentrasi di level tinggi (IQR 95–105), diikuti Fabled (IQR 73–105), sedangkan Normal sangat lebar (IQR 22–86, rentang 1–120). Ini menunjukkan item tier rendah tetap fleksibel dipakai di semua level, sementara item tier tertinggi eksklusif untuk end-game.

## c. Analisis Multivariat — Heatmap Korelasi




*Gambar 3. Heatmap korelasi antar requirement stats.*

- Korelasi antar stat requirement positif sedang–kuat: requirements.level vs stat = 0,64–0,69 (moderat); antar stat, mis. defence–agility = 0,94 dan strength–dexterity = 0,91 (kuat).
- Interpretasi: item pada level tinggi umumnya mensyaratkan beberapa stat sekaligus, dan pasangan stat tertentu (defence–agility, strength–dexterity, intelligence–agility) sering muncul bersamaan. Korelasi level tidak mencapai 1,0 karena banyak item (terutama normal/unique) tidak memiliki requirement stat sama sekali (sel kosong pada matriks).

*Catatan koreksi: interpretasi awal di notebook menyebut korelasi antar stat sangat rendah mendekati 0. Nilai aktual dari matriks korelasi adalah positif kuat (0,64–0,94), sehingga penjelasan pada laporan ini mengacu pada angka hasil perhitungan yang benar.*

## 5. Kesimpulan

1. Dataset berisi 6.725 item dengan 630 atribut hasil normalisasi API yang sangat bersarang.
2. Karakteristik utama: distribusi level left-skewed (fokus end-game), dominasi tier Unique/Rare, dan kelangkaan ekstrem tier Mythic.
3. Kualitas data cukup baik pada kolom inti, dengan missing value terstruktur pada kolom majorIds/identifications yang bermakna domain, bukan kesalahan data.
4. Tidak ada outlier pada requirements.level; outlier negatif baseHealth valid secara desain game.
5. Terdapat korelasi positif sedang–kuat antara level dan stat requirement, serta antar stat requirement, yang mencerminkan mekanisme build berbasis atribut di Wynncraft.

Rekomendasi lanjutan: analisis dapat dilanjutkan dengan feature engineering (menggabungkan kolom identifications.* menjadi fitur numerik agregat), pemisahan analisis per type/subType, serta pemodelan prediksi nilai item jika data ekonomi tersedia.